Informe Final Grupo 9

Análisis Exploratorio de Datos

El problema se abordó como una decisión de otorgar préstamos a solicitudes con presupuesto limitado. Se trabajó con tres archivos: solicitudes_train, comportamiento_bancario y solicitudes_test. La unidad de análisis elegida fue cada solicitud, identificada por ID_Solicitud. Luego, el historial bancario se vinculó a cada solicitud mediante ID_Usuario.

En el análisis exploratorio se revisaron dimensiones, tipos de datos, si había valores faltantes, duplicados y distribuciones. No se observaron nulos en los datos originales revisados ni solicitudes duplicadas en el conjunto combinado (solicitudes y comportamiento bancario). Los gráficos y estadísticas sugieren que los atrasos históricos diferencian los resultados con mayor claridad: la correlación observada entre ***saldo histórico promedio*** y ***Estado_Final*** fue aproximadamente -0,45. La columna ***atrasos históricos promedio*** también pareció aportar información (correlación aproximada de 0,24 con respecto a Estado_Final). El monto solicitado mostró diferencias entre clases, pero no es lo suficientemente claro por sí solo. El motivo del préstamo y la tasa de interés no tienen valor predictivo real de forma aislada.

Feature engineering y prevención de leaks

Se convirtieron las fechas a formato temporal y se unieron las solicitudes con el historial bancario por usuario. Para evitar data leakage, se conservaron únicamente los registros cuyo ***Mes_Referencia*** fuera estrictamente anterior a la ***Fecha_Solicitud.*** Esta decisión se tomó porque el modelo no debe usar información que todavía no existía al momento de evaluar el préstamo. Luego, el historial mensual se resumió por solicitud en **cuatro variables**:

- Saldo_Historico_Promedio
- Atrasos_Historicos_Promedio
- Atrasos_Historicos_Max
- Meses_Historial_Cuenta (cantidad de meses observados)

De esta forma pudimos unificar los dos datasets, manteniendo la información relevante para realizar las predicciones.

Preparación del modelo

Se separó Estado_Final como variable objetivo y se **excluyeron** de las entradas los **IDs, la fecha de solicitud y Motivo_Prestamo**, ya que observamos durante el EDA que no tenían valor predictivo (no explicaban el pago o default de un préstamo). Posteriormente, se dividieron los datos en entrenamiento (80 %) y validación (20 %), con random_state=42 (para mantener la misma seed) y estratificación por clase.

El modelo elegido fue una regresión logística dentro de un pipeline. Las variables numéricas se estandarizan mediante **StandardScaler.** No hizo falta imputar porque ya vimos en el EDA que no había valores faltantes. Además, se usa class_weight='balanced' para compensar el desbalance entre resultados (esto debido a que hay muchísimos más casos donde se pagaba el préstamo frente a los que hacían default). El pipeline nos sirve para luego aplicar las mismas transformaciones a validación y test.

Valentino Carignano, Tomás Cinturión

Aprobación de préstamos

La primera prueba utilizó **predict** para asignar una decisión. En validación obtuvo una exactitud cercana al 77 %, pero las métricas evaluadas no resuelven por sí solas el objetivo del trabajo. Por eso, se pasó a utilizar **predict_proba**, que estima la probabilidad de pago para cada solicitud. Con ella se calculó un **valor esperado o esperanza matemática,** que nos dice cuántos dólares se esperan ganar en total con un préstamo determinado. Luego, calculamos el ROI, que nos dice qué tan eficiente es un préstamo, para exprimir al máximo el presupuesto limitado con el que se cuenta.

Se descartaron las solicitudes con valor esperado no positivo y se ordenaron las restantes de mayor a menor según el ROI esperado. Finalmente, se aprobaron en ese orden mientras el monto acumulado no superara el presupuesto de USD 2.000.000. Una vez que se comprobó que el proceso funcionaba, se replicó para el dataset de test.

Primer enfoque erróneo considerado

En primera instancia, se logró que el modelo prediga pago/default para cada solicitud y se evaluaba mediante precision, recall, F1-score y accuracy. Sin embargo, estas métricas miden la calidad de la clasificación, no la rentabilidad de los préstamos seleccionados.

Por ejemplo, el accuracy del 77% indica que el modelo clasificó correctamente aproximadamente el 77% de las solicitudes de validación. Pero no tiene en cuenta cuánto dinero se ganaría o perdería con cada préstamo, ni el presupuesto disponible. Además, existe un desbalance entre las clases. Por eso, una métrica como accuracy puede dar resultados favorables sin reflejar adecuadamente el desempeño del modelo al predecir ambas clases.

Por otro lado, aunque precision, recall y F1-score permiten analizar los errores de clasificación, tampoco distinguen entre aprobar un préstamo que termina en incumplimiento y rechazar uno que habría sido rentable. Esos errores pueden tener consecuencias económicas muy diferentes.

Por este motivo, se utilizaron las probabilidades estimadas por el modelo para calcular el valor esperado de cada préstamo y su ROI, priorizando las solicitudes más convenientes sin superar el presupuesto disponible.